

Прогнозирование ключевых факторов и скорости устройства животных с помощью методов машинного обучения

Сметанина Алевтина
DSU-79



Актуальность проблемы

-  Высокая нагрузка на приюты и большое количество животных
-  Длительное и труднопрогнозируемое время ожидания пристройства
-  Многие влияющие факторы неочевидны и требуют глубокого анализа
-  Методы машинного обучения позволяют выявить скрытые закономерности и повысить эффективность работы приюта



Основные задачи работы

- Провести анализ исходных данных.
- Выполнить предобработку данных.
- Построить и обучить несколько моделей машинного обучения.
- Оценить качество моделей с использованием метрики Quadratic Weighted Kappa.
- Проанализировать значимость признаков, влияющих на скорость устройства животных.
- Сформулировать выводы и возможные направления развития модели.

Цель:

**Разработка модели
машинного обучения для
прогнозирования времени
до устройства и анализ
факторов, влияющих на
это**



Описание данных

Источник данных:

Открытый датасет **PetFinder Adoption Prediction**

Основные типы признаков:


- Числовые (возраст, количество фото и т.д.)
- Категориальные (порода, размер, пол и т.д.)
- Текстовые (описание животного)

Особенности данных:

- Наличие пропущенных значений
- Смешанный тип данных
- Возможное влияние субъективных факторов (описания, качество фотографий)



Несбалансированность по целевой переменной



Обработка данных

Обработка пропусков и выбросов

Пропуски:


- Name (23) → "NoName"
- Description (87) → пустая строка

Выбросы:

- Age > 240 месяцев → медиана (3 месяца)
- Fee → 95-й перцентиль (значение 150)
- PhotoAmt, VideoAmt → без изменений




Выбросы



Распределение после обработки данных

Распределение числовых признаков после обработки выбросов



Обработка данных

Новые признаки


- Description_len — длина описания в словах
- Description_lem — лемматизированный текст (WordNetLemmatizer, NLTK)

Разделение данных


Преобразование признаков



Распределение по категориям



Распределение по категориям



Подтверждение гипотезы



Vaccinated: **89.85%** животных до 1 года (≤ 12 месяцев) среди всех 'No' или 'Unknown' (8172/9095)



Dewormed: **88.10%** животных до 1 года (≤ 12 месяцев) среди всех 'No' или 'Unknown' (5811/6596)



Sterilized: **88.84%** животных до 1 года (≤ 12 месяцев) среди всех 'No' или 'Unknown' (10565/11892)



Рассматриваемые модели

Для решения задачи были выбраны следующие алгоритмы:

- RandomForest
- LightGBM
- CatBoost
- В качестве базовой модели использовался DummyClassifier

Для повышения качества моделей применялись:

- GridSearchCV - для RandomForest и LightGBM (подбор по сетке)
- Optuna - для CatBoost (байесовская оптимизация, 5 trials)



Архитектура решения

Этап 1. Предобработка данных:

- Обработка пропусков и выбросов
- Лемматизация текста (WordNetLemmatizer)
- Создание признака Description_len

Этап 2. Подготовка признаков:

- Числовые признаки → StandardScaler (5 признаков)
- Категориальные признаки → One-Hot Encoding (8 → 8 бинарных)
- Текстовые признаки → TF-IDF (500 признаков)
- Итоговый набор: 513 признаков

Этап 3. Обучение и валидация:

- Разделение 80/20 с stratify=y (train 11994, test 2999)
- 3-fold кросс-валидация при подборе параметров
- Оценка качества на тестовой выборке

Этап 4. Интерпретация:

- Анализ важности признаков (feature importance)
- SHAP-анализ для лучшей модели (CatBoost Optuna)



Обучение моделей

Метрика качества: Quadratic Weighted Kappa (QWK)

$$QWK = 1 - \frac{\sum_{i,j} w_{i,j} O_{i,j}}{\sum_{i,j} w_{i,j} E_{i,j}}$$

где:

- $O_{i,j}$ – наблюдаемая матрица ошибок (confusion matrix)
- $E_{i,j}$ – ожидаемая матрица ошибок при случайном предсказании
- $w_{i,j}$ – квадратичные веса, определяемые как

$$w_{i,j} = \frac{(i-j)^2}{(N-1)^2}$$

где N – количество классов (в данном случае 5).



Обучение моделей

Этап 1. Обучение базовых моделей с параметрами по умолчанию

- RandomForestClassifier (n_estimators=200, max_depth=10, class_weight='balanced')
- LGBMClassifier (n_estimators=500, learning_rate=0.05)
- CatBoostClassifier (iterations=500, learning_rate=0.05, depth=6)

Этап 2. Оптимизация гиперпараметров

- Для RandomForest и LightGBM использовался GridSearchCV с 3-кратной кросс-валидацией.
- Для LightGBM перебирались параметры с акцентом на регуляризацию для борьбы с переобучением.
- Для CatBoost, ввиду высокой вычислительной стоимости полного перебора, использовалась байесовская оптимизация с помощью библиотеки Optuna (5 trials, 3-кратная кросс-валидация).

+ Кросс-валидация

При подборе гиперпараметров использовалась 3-кратная стратифицированная кросс-валидация (StratifiedKFold).



Интерпретация моделей

Для интерпретации результатов использовались два подхода:

- **Анализ важности признаков (Feature Importance):** встроенные механизмы RandomForest, LightGBM и CatBoost позволяют оценить вклад каждого признака в предсказания модели
- **SHAP-анализ:** для лучшей стабильной модели (CatBoost Optuna) был проведён SHAP-анализ, позволяющий не только оценить важность признаков, но и понять направление их влияния (увеличивают или уменьшают скорость устройства).



Итоговые параметры лучших моделей

RandomForest (GridSearch):

- **n_estimators: 200**
- **max_depth: None**
(без ограничений)
- **class_weight:**
'balanced'

LightGBM (GridSearch):

- **max_depth: 10**
- **reg_alpha: 0**
- **reg_lambda: 0.1**
- **class_weight:**
'balanced'


CatBoost (Optuna):

- **depth: 5**
- **learning_rate: 0.0893**
- **l2_leaf_reg: 4**
- **iterations: 200**




Сравнение моделей


Сравнение качества моделей




Переобучение (чем меньше - тем лучше)



ТОП-20 САМЫХ ВАЖНЫХ ПРИЗНАКОВ (CatBoost Optuna)



SHAP-анализ



Ключевые наблюдения:



Числовые признаки доминируют в топе: **Age** и **PhotoAmt** - самые важные



Категориальные признаки (**Sterilized**, **Type**, **FurLength**, **Gender**, **MaturitySize**) в сумме дают большой вклад



Текстовые признаки также значимы:

- Слова "adoption", "interested" - маркеры заинтересованности
- "whatsapp" - указание контакта для связи (важный практический инсайт!)
- Служебные слова ("for", "are", "and") тоже появляются, что типично для TF-IDF
- **Description_len** (длина описания) замыкает топ - важно, но не критично



Практические рекомендации для приюта

1. **Фотографии** - делать минимум 3-5 качественных фотографий каждого животного
2. **Возраст** - разработать отдельные программы продвижения для пожилых животных
3. **Стерилизация** - проводить её до размещения объявления
4. **Описания** - обязательно указывать контакт для связи (whatsapp, e-mail)
5. **Ключевые слова** - использовать в описании слова: adoption, interested, home, love
6. **Особые категории** - для крупных животных и животных с длинной шерстью давать дополнительные пояснения



Заключение

В ходе выполнения работы была достигнута поставленная цель: разработаны модели машинного обучения для прогнозирования скорости пристройства животных из приюта и выявлены ключевые факторы, влияющие на этот процесс.

Практическое применение моделей

- Прогнозирование скорости пристройства новых животных
- Оптимизация объявлений на основе ключевых факторов
- Выявление животных с низкими шансами (пожилые, крупные, с длинной шерстью)



Направления дальнейшего развития

Улучшение моделей:

- Провести более глубокую оптимизацию CatBoost
- Исследовать ансамблирование лучших моделей

Расширение данных:

- Добавить данные из других приютов для проверки универсальности моделей
- Включить возможные дополнительные признаки

Внедрение в практику:

- Разработать веб-интерфейс для сотрудников приюта
- Создать рекомендательную систему для потенциальных усыновителей
- Провести A/B тестирование эффективности рекомендаций



**Спасибо за
внимание!**

